

RNA-seq解析 基本フォーマットとツール

Basic Formats and Tools of RNA-seq analysis

NIBB

2024 Genome Informatics Training Course

Hiroyo NISHIDE🐱 (hiroyo@nibb.ac.jp, @piroyon🐦🐙)

この時間の内容

1. UNIXシステムとそのコマンド quick lecture
2. NGSで扱うデータのフォーマット
3. ショートリードのリファレンスゲノムへのマッピング
4. マッピングのオプションとマッピング結果の見方

UNIX基本コマンドとファイルシステム quick lecture

- UNIXでしか使えないアプリケーション
 - 最新の研究用ソフト
 - 並列化・大容量メモリ対応ソフト
- たくさんの処理を一度に行う
 - スクリプトを用いたコマンドの連続実行
- 自作プログラム
 - シェルスクリプト, Python, Perl, Ruby, バイオ系ライブラリ
- Webサーバ、データベースサーバ
 - 高い安定性
 - ApacheやMySQL, Postgresなどのサーバ用フリーソフト

UNIXのファイル置き場は階層型ディレクトリ




- UNIXにおけるディレクトリ = PCでのフォルダ
- トップのルートディレクトリ下に、子ディレクトリ、孫ディレクトリがあり、ファイルを配置する
- ディレクトリ階層は「/」で区切って表示する（例：/home/course00/data）

ルートディレクトリ（/）：ディレクトリの頂点

ホームディレクトリ（~）：個々のユーザ専用ディレクトリ

カレントディレクトリ（.）：現在の作業ディレクトリ
プログラムが作成するファイルは、プログラム起動時のカレントディレクトリに作成される



親ディレクトリ（..）：カレントディレクトリのひとつ上のディレクトリ ドット2つで表記する

ディレクトリの中身を見る (**ls**)

- **ls**

- カレントディレクトリの内容（ファイル名のリスト）を表示する

- **ls** ディレクトリ名

- 指定したディレクトリの内容を表示する

```
$ ls data
```

dataディレクトリの内容を表示

```
$ ls /
```

ルートディレクトリの内容を表示

```
$ ls ..
```

ひとつ上のディレクトリの内容を表示

- **ls -l** ディレクトリ名 or ファイル名

- 指定したディレクトリまたはファイルの内容をファイルの詳細と共に表示する

- **ls -a**

- ファイル名の先頭がドット（.）で始まる隠しファイルを含めて表示する

- **ls -la**

- （オプションは2つ同時に付けられる）

ディレクトリを移動する (**cd**)

- **cd** ディレクトリ名

- 指定したディレクトリに移動する
- カレントディレクトリの変更

```
$ cd gitc
```

gitcディレクトリに移動

```
$ cd ..
```

階層がひとつ上のディレクトリ(..)に移動

```
$ cd gitc/data/HN
```

gitc、さらに下の data/HN ディレクトリまで移動

```
$ cd
```

ホームディレクトリ(~)に移動

(ディレクトリ名を省略すると、ホームディレクトリに移動する **cd ~** と同義)

- **pwd**

- カレントディレクトリの確認

ディレクトリの作成と削除 (**mkdir**, **rmdir**)

- **mkdir** ディレクトリ名

- 新規ディレクトリの作成

```
$ mkdir unixtest
```

- **rmdir** ディレクトリ名



- 空のディレクトリの削除

```
$ rmdir unixtest
```

- ディレクトリ内にファイルがあると削除できない

ファイル/ディレクトリのコピー (cp)

- **cp** file1 file2
 - file1のコピーをfile2として作成
- **cp** file1 [file2...] dir
 - file1 (,file2,...) のコピーをdir 内に作成
- **cp** **-r** dir1 dir2
 - dir1をdir2としてディレクトリごとコピーを作成
 - コピー先のディレクトリが存在する場合は、そのディレクトリ以下にdir1として作成



```
$ cd gitc/data/HN
$ cp sox6.gtf copy.gtf
```

同一名ファイルが存在すると上書きされるので注意！

ファイル/ディレクトリ名の変更、移動 (**mv**)


- **mv** file1 file2

- file1の名前を file2 に変更

```
$ mv copy.gtf rename.gtf
```

- **mv** file1 [file2...] dir

- file1 (,file2,...) をdir内に移動



同一名ファイルが存在すると上書きされるので注意！

ファイルの削除 (**rm**)

- **rm** ファイル名 ...

- 指定したファイルを削除する

```
$ rm rename.gif
```

- **rm -rf** ディレクトリ名

- ディレクトリの中身を確認なしで全て消去した上でディレクトリを削除する
- 確認しながら消去するには **rm -ri** とする

- UNIXに「ゴミ箱」はありません！

- 削除したファイルを復活することはできません

ファイルの中身を見る(**less**)

- **less** ファイル名

- ファイルの内容を閲覧する
- ページの移動には独自のキー操作が必要

```
$ less eco_o139_cds.gff
```

キー操作	説明
f, SPACE	1 ページ先へ進む
b	1 ページ前へ戻る
j, k	1 行ずつ前(j)後(k)へ移動
g, G	ファイルの先頭(g)、末尾(G)へ移動
/文字列	文字列の検索、n,Nで前後のヒット行へ移動
q	終了

パターン検索(**grep**)

- **grep** パターン ファイル名...

- ファイル中でパターンを含む行を出力

```
$ grep rpoN eco_o139_cds.gff
```

eco_o139_cds.gff から rpoN を含む行を検索

```
$ grep ^@SRR etec_1.fq
```

etec_1.fq から「@SRR」で始まる行を検索
("^^" は行の先頭を意味する)

行数・単語数のカウント(**wc**)

- **wc** ファイル名

- ファイルの行数、単語数、文字数を出力

```
$ wc eco_o139.fa
```

```
65626    65655 5315215 eco_o139.fa
```

(65,626行、65,655単語、5,315,215文字)

リダイレクト

- ・ コマンドの結果はデフォルトでは「画面」に出力される
- ・ 「リダイレクト」によって、出力を画面「以外」にする
- ・ 画面に出力（デフォルトの動作）

```
$ grep ^@SRR etec_1.fq
```

- ・ ファイルに保存 (>)
 - ・ コマンドの右側に " > filename" を加える
 - ・ 結果を fastq_list というファイルに保存

```
$ grep ^@SRR etec_1.fq > fastq_list
```

(同名ファイルがある場合は上書きされる)

- ・ 存在するファイルに追加書き (>>)
 - ・ コマンドの右側に " >> filename" を加える

```
$ grep ^@SRR etec_2.fq >> fastq_list
```

(ファイルが存在しない場合は作成される)

パイプによるコマンドの結合

- コマンド間を縦棒 (|) でつなげる。 「|」をパイプと呼ぶ
- 前のコマンドの出力が次のコマンドの入力となる

- `grep` の出力行数を `wc` で数える

```
$ grep ^@SRR etec_1.fq | wc
```

- `grep` の結果を `less` で見る

```
$ grep tRNA eco_o139_cds.gff | less
```

- `grep` の結果をさらに `grep` して絞り込む

```
$ grep tRNA eco_o139_cds.gff | grep thr | less
```

- コマンドはいくつでも結合できる

UNIXコマンド実行の基本形

```
ls -l gbre1.txt
```

コマンド/
プログラム名

オプション
コマンドの動作を
変えるスイッチ

オペランド
ファイルなど コマン
ドが処理する対象

引数

解析プログラム実行例になると...

実行プログラム名

```
bowtie2 -x etec -U mydata.fq -S etec_bowtie2.sam
```

マップ先データベース指定

データベース名

マップ元 fastq
ファイル指定
(Single end)

fastqファイル名

出力フォーマット指定
(SAM)

出力するファイル名

次世代シーケンサー(NGS)で扱うファイルのフォーマットについて

- フォーマット？ format

- データを記録する際のルール

ルールがあれば情報を効率よく、正確に共有することができる

コンピューターの世界ではフォーマットを共有することで仲良くしている

例) 音楽はMP3, 動画はMP4, WebページはHTML, 見た目が崩れない文書PDF... etc

- NGSで扱うデータは基本テキストファイル

(**半角**で 英数字/記号/改行/スペース/タブのみのファイル)


- データの「記述方法」にルールがあり、そのルールこそがフォーマットとなっている

NGS解析の流れとデータファイルのフォーマット（ここでは5種）

FASTA フォーマット
(ゲノム核酸配列：リファレンスとして使う)

```
>chr
AGCTTTTCATTCTGACTGCAACGGGCAATATGTCT
CTGTGTGGATTAAAAAAGAGTGTCTGATAGCAGC
TTCTGAACCTGGTTACCTGCCGTGAGTAAATTA
TTTTATTGACTTAGGTCACTAAATACTTTAACCAA
TATAGGCATAGCGCACAGACAGATAAAAATTACAG
AGTACACAACATCCATGAAACGCATTAGCACCACC
```


①NGSで読んだ
ショートリードのサンプル



FASTQ フォーマット
(短いDNA配列とその品質)

```
@SRR1515276.1 HWI-ST808:151:D2D13ACXX:2:1207:3625:88631 length=51
ATCCGGCTGGCGCACCGACCTATGTTCCGGGCGAATACAAGCTGGGTGAAG
+SRR1515276.1 HWI-ST808:151:D2D13ACXX:2:1207:3625:88631 length=51
@@@AD>DDFF7DC?FFEBF@DFII<DF@AAA6AEFBDCA?>A?B=>B::
@SRR1515276.2 HWI-ST808:151:D2D13ACXX:2:1207:3871:88513 length=51
CACCGTGTAGTACCAGCATCCTGCGTACAATCAGCAATCCCAGTCCCTCCCC
+SRR1515276.2 HWI-ST808:151:D2D13ACXX:2:1207:3871:88513 length=51
CCCFDFDFHDFHDFHIIIEGIHJJJGFGHGGHGGHGGIJDGIJHHGGGHHI
@SRR1515276.3 HWI-ST808:151:D2D13ACXX:2:1207:3950:88530 length=51
CAGGACATCGCCTTTGATCGGTTTCAGACTTCGGACCAACCTGCATTTTCAG
+SRR1515276.3 HWI-ST808:151:D2D13ACXX:2:1207:3950:88530 length=51
CCCFDFDFAFHFHFIJGHIJJIJJJHEHIIJGHIFEHIIA@FIFHGGIIGI
```

②リファレンス配列へのマッピング



マッピングの
ためのヒント

GTF (GFF3) フォーマット
(ゲノムのどこに遺伝子があるか)

chr	RefSeq	start_codon	190	192	1.000	+	.	gene_id	"b0001"; transcript_id	"b0001";
chr	RefSeq	CDS	190	252	1.000	+	0	gene_id	"b0001"; transcript_id	"b0001";
chr	RefSeq	stop_codon	253	255	1.000	+	.	gene_id	"b0001"; transcript_id	"b0001";
chr	RefSeq	exon	190	255	1.000	+	.	gene_id	"b0001"; transcript_id	"b0001";

③マッピングの結果をゲット

SAM フォーマット (マッピングの結果)

@HD	VN:1.0	SO:unsorted								
@SQ	SN:chr	LN:4639675								
@PG	ID:bowtie2	PN:bowtie2	VN:2.2.4	CL:"/bio/bin/bowtie2-align						
SRR1515276.40	0	chr	4423609	42	51M	*	0	0	GGAATTCCTCACTGCCA	
SRR1515276.158	16	chr	501700	42	51M	*	0	0	ACGCACCGAGTGCAAAG	
SRR1515276.212	4	*	0	0	*	*	0	0	GGCCGCTTTTCAGCGTGT	
SRR1515276.319	0	chr	2922768	42	51M	*	0	0	GCTTAAGTTGATTAAGG	
SRR1515276.367	16	chr	2753873	42	51M	*	0	0	GCGTGTCCGTCGCCAGC	
SRR1515276.411	0	chr	3440721	42	51M	*	0	0	ACGGCATAATTCTTGA	
SRR1515276.434	0	chr	4198737	42	51M	*	0	0	GCGCGGTACGCATCTGG	

④コンピュータが扱いやすい
フォーマットに変換

BAM フォーマット
(情報の内容はSAMと同じ)

早速やってみよう

bowtie2を利用したリファレンスゲノムへのショートリードマッピング

実習用ディレクトリ ~/gitc/data/HN

必要なもの2点：

1. リファレンスとして使うためのゲノム配列

- **FASTA** フォーマット：NCBIからダウンロードした腸管毒素原性大腸菌(ETEC) O139:H28のゲノム配列

`eco_o139.fa`

2. NGSで読んだショートリードのサンプル

- **FASTQ** フォーマット, paired-end, アダプター除去済

`etec_1.cut.fq`

`etec_2.cut.fq`

ペアエンドリードなので
ファイルは2つ

マッピングの前に

bowtie2でマッピングをするには、リファレンスゲノム配列にインデックスが必要

◆bowtie2用インデックスの作成（インデックス名は **etec** とする）

```
$ bowtie2-build eco_o139.fa etec
```

下記の6つのファイルが自動で作られる。これらはbowtie2が使うことのできるインデックスファイルであり、人間が直接中を見たりすることはない

etec.1.bt2, etec.2.bt2, etec.3.bt2, etec.4.bt2, etec.rev.1.bt2, etec.rev.2.bt2

bowtie2の実行 (paired-end)

- ◆ bowtie2によるマッピングの実行
- ◆ 先ほど作成した「etec」インデックスを使う
(結果ファイル名: **etec_bowtie2.sam** とする)

```
$ bowtie2 -x etec -1 etec_1.cut.fq -2 etec_2.cut.fq  
-S etec_bowtie2.sam
```

SAMフォーマットのマッピング結果 **etec_bowtie2.sam** が得られた

- 本来はマッピングする前に、FASTQファイルの
 - リードのクオリティ確認
 - アダプター配列の除去

などが必要です。詳細は先回のGITC

- 「クオリティコントロールとNGS基本ツール」

を参照のこと

<https://github.com/nibb-unix/gitc202402-unix/wiki>

次世代シーケンサー(NGS)で扱うファイルのフォーマットについて

ここまでで3種類のフォーマットを扱った

1. FASTA
2. FASTQ
3. SAM

それぞれ何のファイルだったか覚えていますか？

FASTA (.fasta .fa .mfa)

概要	配列情報の標準フォーマット	
内容	核酸配列 アミノ酸配列	
	公共データベースにあるゲノム配列や遺伝子配列など	
規則	<u>配列タイトル+配列のセット</u>	
	配列タイトル	">" で始まる一行 >pETEC_80 Escherichia coli E24377A 配列ID その説明 (スペース区切り)
	配列	タイトル行の改行後に記載、配列は改行可能

ファイル例

```
>ETEC_chr Escherichia coli E24377A, complete genome
AGCTTTTCATTCTGACTGCAACGGGCAATATGTCTCTGTGTGGATTAAAAAA
GAGTGTCTGATAGCAGCTTCTGAACCTGGTTACCTGCCGTGAGTAAATTAAAAT
TTTATTGACTTAGGTCACTAAATACTTTAACCAATATAGGCATAGCGCACA
>pETEC_80 Escherichia coli E24377A plasmid
TTCAGATTAAACACTCCAACATCACCGCGGGCAACTTTGCGCTGAATGCGACA
GTGGCCGGCTCTGAAATCAGCAATACCACGCTGACGGCCACCACCAACATCAA
CCTGACGGCTAAGACGAACAGTGCGAGTTCTGGTGTTTACCTGAAAGAT
```

← タイトル行

← 配列

FASTAを見てみよう

```
$ less eco_o139.fa
```

FASTQ (.fastq .fq) FASTA+Quality

概要	NGS 結果の実質的な標準フォーマット	
内容	塩基配列、一塩基ごとの品質情報 (Quality value)	
	マッピング、アセンブル時の入力データ形式	
規則	4行で1セット (1リード)	
	1行目	"@"で始まるタイトル行 (配列IDや説明)
	2行目	塩基配列 改行しない
	3行目	"+" で始まるタイトル (+以降は省略可)
	4行目	上記塩基配列の一塩基ごとのクオリティ (Quality value)

ファイル例

```
@SEQ_ID1
GATTTGGGGTTCAAAGCAGTATCGATCAAATAGTAAATCCATTTGTTCAACTCACAGTTT
+
!'*(((((***+))%%%+))(%%%).1***-+*''))**55CCF>>>>>CCCCCCC65
@SEQ_ID2
GATCAAATAGTAAATCCATTTGTTCAACTCACAGTTTGATTTGGGGTTCAAAGCAGTATC
+
(%%%).1***-+*''))**55CCF>>>>>CCCCCCC65!'*(((((***+))%%%+))
```

← 配列 ID

← 塩基配列

← タイトル (今回は省略)

← クオリティ(QV)

FASTQを見てみよう

```
$ less etec_1.cut.fq
```

ファイル例

概要	マッピング（アライメント）結果を表現する標準フォーマット
	SNP、発現量解析への入力データ形式

ヘッダ (@で始まる)

リファレンス配列に関する情報

```

@HD      VN:1.0      SO:unsorted
@SQ      SN:ETEC_chr      LN:4979619
@SQ      SN:pETEC_80      LN:79237
@SQ      SN:pETEC_35      LN:34367
@SQ      SN:pETEC_73      LN:70609
@SQ      SN:pETEC_6       LN:6199
@SQ      SN:pETEC_74      LN:74224
@SQ      SN:pETEC_5       LN:5033
@PG      ID:bowtie2      PN:bowtie2      VN:2.3.0      CL:"/bio/bin/bowtie2-align-s --wrapper basic-0 -x etec -S etec_bowtie2.sam -1 etec_1.cut.fq -2 etec_2.cut.fq"
SRR345261.25      89      ETEC_chr      3758170      1      49M      =      3758170      0      ACACGCGGCATGGCTG...      ###?ED>EBDBDDE,E...      AS:i:-1      XS:i:-1      XN:i:0      XM:i:1      XO:i:0      XG:i:0      NM:i:1      MD:Z:24T24      YT:Z:UP
SRR345261.25      133      ETEC_chr      3758170      0      *      =      3758170      0      NNNNNNNNNNNNNNNN...      #####...      YT:Z:UP      YF:Z:NS
SRR345261.50      73      ETEC_chr      4361458      1      49M      =      4361458      0      CAAGCGTTAATCGGAA...      :HEGDFHHHH@BGG=B...      AS:i:0      XS:i:0      XN:i:0      XM:i:0      XO:i:0      XG:i:0      NM:i:0      MD:Z:49      YT:Z:UP
SRR345261.50      133      ETEC_chr      4361458      0      *      =      4361458      0      NNNNNNNATNNNNNNN...      #####...      YT:Z:UP      YF:Z:NS
SRR345261.75      73      ETEC_chr      4362922      1      49M      =      4362922      0      CGGTGGATGCCCTGGC...      DDDDBD6<B>DB>BB>1>>      AS:i:-2      XS:i:-2      XN:i:0      XM:i:1      XO:i:0      XG:i:0      NM:i:1      MD:Z:37T11      YT:Z:UP
SRR345261.75      133      ETEC_chr      4362922      0      *      =      4362922      0      NNNNNNTTTNNNTCGG...      #####...      YT:Z:UP      YF:Z:NS
SRR345261.100      73      ETEC_chr      679991      42      49M      =      679991      0      GTGGTTAATGAGTCC...      GGGGGGGGB=ED=EEG...      AS:i:0      XN:i:0      XM:i:0      XO:i:0      XG:i:0      NM:i:0      MD:Z:49      YT:Z:UP
SRR345261.100      133      ETEC_chr      679991      0      *      =      679991      0      NNNNNNCACCGNTAGT...      #####...      YT:Z:UP      YF:Z:NS
SRR345261.125      73      ETEC_chr      4376280      42      49M      =      4376280      0      CTCAGGATGAGGGTCA...      EEEE=B<@BDEEDE:...      AS:i:0      XN:i:0      XM:i:0      XO:i:0      XG:i:0      NM:i:0      MD:Z:49      YT:Z:UP
SRR345261.125      133      ETEC_chr      4376280      0      *      =      4376280      0      NNNNNTTTTCNTTAG...      #####...      YT:Z:UP      YF:Z:NS
SRR345261.150      89      ETEC_chr      779844      42      49M      =      779844      0      TTCAGGAAACCTGAA...      B@8D>ECC?BG@ECC>...      AS:i:-5      XN:i:0      XM:i:1      XO:i:0      XG:i:0      NM:i:1      MD:Z:43T5      YT:Z:UP
SRR345261.150      133      ETEC_chr      779844      0      *      =      779844      0      CNCGGAGTACNTTGA...      #####...      YT:Z:UP      YF:Z:NS
SRR345261.175      83      ETEC_chr      3605306      42      49M      =      3605113      -242      CCGCTTGC CGCGGCCA...      EDE<8??;?@DGGDDE...      AS:i:0      XN:i:0      XM:i:0      XO:i:0      XG:i:0      NM:i:0      MD:Z:49      YS:i:-3      YT:Z:CP
SRR345261.175      163      ETEC_chr      3605113      42      49M      =      3605306      242      CCGGGTTCTGTCTGTG...      DGGDGFDDGGGGGEGD...      AS:i:-3      XN:i:0      XM:i:3      XO:i:0      XG:i:0      NM:i:3      MD:Z:38A6C2T0      YS:i:0      YT:Z:CP
SRR345261.200      77      *      0      0      *      *      0      0      AAAAAAAAAAAAAA...      #####...      YT:Z:UP
SRR345261.200      141      *      0      0      *      *      0      0      AAAAAAAAAAAAAA...      8#####...      YT:Z:UP
SRR345261.225      83      ETEC_chr      2879707      1      49M      =      2879600      -156      CACAACACGAGCTGAC...      8?D8BEBGD@GG8GCE...      AS:i:0      XS:i:0      XN:i:0      XM:i:0      XO:i:0      XG:i:0      NM:i:0      MD:Z:49      YS:i:-1      YT:Z:CP
SRR345261.225      163      ETEC_chr      2879600      1      49M      =      2879707      156      CCCACCTTCCTCCAGT...      GGBGBDEGGG@GG<G8...      AS:i:-1      XS:i:-1      XN:i:0      XM:i:1      XO:i:0      XG:i:0      NM:i:1      MD:Z:45G3      YS:i:0
SRR345261.250      99      ETEC_chr      4361346      1      49M      =      4361525      228      GTACTTTCAGCGGGGA...      ECE=>EC?FDG<EGDA...      AS:i:0      XS:i:0      XN:i:0      XM:i:0      XO:i:0      XG:i:0      NM:i:0      MD:Z:49      YS:i:0      YT:Z:CP
SRR345261.250      147      ETEC_chr      4361525      1      49M      =      4361346      -228      CCGGGCTCAACTGGG...      #####BC...      AS:i:0      XS:i:0      XN:i:0      XM:i:0      XO:i:0      XG:i:0      NM:i:0      MD:Z:49      YS:i:0      YT:Z:CP

```

同じ名前のリード = ペアエンドのリード対

FLAG

マップされた染色体と位置 (* はマップされなかった)

MAPQ

CIGAR

ペアの相手がマップされた染色体 (同じなら=) と位置、フラグメントの長さ (右側のリードは負値)

リード配列

配列クオリティ値

オプション

AS アライメントスコア

YS 他の位置でのベストスコア

g out され

SAMを見よう

\$ less etec_bowtie2.sam

samtools を使ってSAMからBAMへのフォーマット変換

人が読めるテキストデータのSAMから、コンピュータが扱い易いBAM（圧縮したバイナリデータ）へ変換する

必要なもの1点

マッピングの結果得られたファイル

SAM フォーマット `etec_bowtie2.sam`

◆SAMからBAMへ変換する（結果ファイル名：`etec_bowtie2.bam` とする）

```
$ samtools view -b etec_bowtie2.sam -o etec_bowtie2.bam
```

◆作成したBAMファイルをヘッダ付きでSAMに変換してlessで表示する

```
$ samtools view -h etec_bowtie2.bam | less
```

- SAM -> BAM でファイルの容量が小さくなり、その先の処理速度も速くなる
- フォーマットが変わっただけであり、ファイル内の情報量はSAM, BAMで同じ
- BAMを less で直接見ることはできない（テキストファイルではない！）

その他の重要フォーマット：

GFF/GTF/GFF3(.gff/gtf/gff3) , BED (.bed)

概要	ゲノム配列上の特徴を表現する（アノテーション）	
内容	遺伝子の染色体上の位置 向き エキソン構造等	
	公共データベースにゲノム配列とセットであることが多い 解析したい領域の指定 アノテーション作業 遺伝子構造予測ソフトの結果出力	
4形式 の 特徴	GFF	拡張性が高く様々な特徴情報を記録可能
	GTF	GFF の厳格化版 一貫した規則で特徴情報を記録可能
	GFF3	GTF（GFF version2）の改良版
	BED	ブラウザでの描画情報（色など）を記録可能

GFFを見てみよう

\$ less eco_o139_cds.gff

- 今回紹介したフォーマットの詳細は、先回のGITC
「NGS基本データフォーマット」

を参照のこと

<https://github.com/nibb-unix/gitc202402-unix/wiki>

- 分子生物学研究で使われるデータフォーマットには他にも
様々なものがある

最後に BAMのインデックス作成と検索

BAMフォーマットファイルを扱いやすくするためにソートし、インデックスを作成する

必要なもの1点

SAMからBAMに変換したファイル

BAM フォーマット

etec_bowtie2.bam

BAMのインデックスは、次の講義「NGS可視化ツールIGV」でも必要です！

◆リファレンス配列上の位置の順にソート（結果ファイル名：**etec_bowtie2_sorted.bam** とする）


```
$ samtools sort etec_bowtie2.bam -o etec_bowtie2_sorted.bam
```

◆ソートされたBAMファイルに対してインデックスを作成する（インデックス.baiファイルが自動でできる）

```
$ samtools index etec_bowtie2_sorted.bam
```

◆インデックスを使って、リファレンスの染色体配列(染色体名：ETEC_chr)の10000-12000 の範囲にマッピングされた結果のみを表示する

```
$ samtools view etec_bowtie2_sorted.bam ETEC_chr:10000-12000
```



ここまで bowtie2 と samtools を使った

- アプリケーションの使い方、指定可能なオプションの確認

コマンドライン上でヘルプの参照

- プログラム名の後ろに **-help --help -h** などを付けて実行してみる
- オプション無しで実行してみる

```
$ bowtie2 -h
Bowtie 2 version 2.4.5 by Ben Langmead (langmea@cs.jhu.edu, www.cs.jhu.edu/~langmea)
Usage:
  bowtie2 [options]* -x <bt2-idx> {-1 <m1> -2 <m2> | -U <r> | --interleaved
<i> | -b <bam>} [-S <sam>]

<bt2-idx>  Index filename prefix (minus trailing .X.bt2).
           NOTE: Bowtie 1 and Bowtie 2 indexes are not compatible.
<m1>      Files with #1 mates, paired with files in <m2>.
           Could be gzip'ed (extension: .gz) or bzip2'ed (extension: .bz2).
<m2>      Files with #2 mates, paired with files in <m1>.
           Could be gzip'ed (extension: .gz) or bzip2'ed (extension: .bz2).
<r>       Files with unpaired reads.
           Could be gzip'ed (extension: .gz) or bzip2'ed (extension: .bz2).
```

samtoolsの使い方
を見てみよう

\$ samtools

Webページなどでドキュメント/マニュアルを参照

- 可能な限り本家サイトをあたる



Introduction

[How is Bowtie 2 different from Bowtie 1?](#)

[What isn't Bowtie 2?](#)

Obtaining Bowtie 2

[Building from source](#)

[Adding to PATH](#)

The bowtie2 aligner

[End-to-end alignment versus local alignment](#)

[End-to-end alignment example](#)

[Local alignment example](#)

[Scores: higher = more similar](#)

[End-to-end alignment score example](#)

[Local alignment score example](#)

[Valid alignments meet or exceed the minimum score threshold](#)

[Mapping quality: higher = more unique](#)

Aligning pairs

[Paired inputs](#)

[Paired SAM output](#)


[Concordant pairs match pair expectations, discordant pairs don't](#)

[Mixed mode: paired where possible, unpaired otherwise](#)

[Some SAM FLAGS describe paired-end properties](#)

[Some SAM optional fields describe more paired-end properties](#)

[Mates can overlap, contain, or dovetail each other](#)



Home

Brian Haas edited this page on 10 Jun · 38 revisions

RNA-Seq De novo Assembly Using Trinity



Quick Guide for the Impatient

Trinity assembles transcript sequences from Illumina RNA-Seq data.

Download Trinity [here](#).


Build Trinity by typing 'make' in the base installation directory.

Assemble RNA-Seq data like so:


```
Trinity --seqType fq --left reads_1.fq --right reads_2.fq --CPU 6 --max_
```

Bowtie2のオプション1

ペアエンドリード対の検索



- **-I** *min_length* フラグメント長の最小値 (default: 0)
- **-X** *max_length* フラグメント長の最大値 (default: 500)
- **--fr** / **--rf** / **--ff** リード1とリード2の相対的な向き (default: fr)



- 条件を満たさない(discordant)リード対もデフォルトでは出力される。その際、2カラム目(FLAG)の2ビット目（ペアが正しくアラインされたか？）に0がセットされる。

Bowtie2のオプション2

アライメント出力のモード

Bowtie2におけるスコア =
ミスマッチに対するペナルティ

- 一般に、1つのリードは複数の箇所にマップされる。



- `default` (`best one mode`)

条件を満たすアライメントを検索し、最高スコアのものを1つ出力
(ただし、検索は完全でないので、最高スコアを取りこぼす可能性はある)
上記の例では、BまたはD (どちらかがランダムに選ばれる)

- `-a` 条件を満たすアライメントをすべて出力 上記の例では、A,B,C,D,E


- `-k` `num_of_alignment`

条件を満たすアライメントを、見つかった順に指定した数だけ出力
上記の例で、`-k 2` のとき、左から順に見つかるとうすると、AとBが出力される
(実際には位置の順に見つかるわけではない)

- `-a` や `-k` を指定したとき、最高スコアでないアライメントには9番目のフラグ
(`secondary alignment`)に1がセットされる


(参考) Bowtie2におけるアライメントスコア

- マッチは0で、ミスマッチにマイナスのペナルティ（最高スコアは0点）
- ミスマッチペナルティは、クオリティ値に応じて -2 から -6 の値をとる（下図）
- あいまい塩基（N）のペナルティは -1
- ギャップペナルティは、ギャップの長さ n に対して $-(5 + 3n)$
- スコアのカットオフは、長さ L に対して $-0.6(L+1)$



(参考) *De novo* Assembly によるRNA-Seq解析

デノボ・アセンブルによる転写配列の構築



マッピング結果：マッピングクオリティ (MAPQ)

- マッピングクオリティ (MAPQ) 値は以下の式で計算される。

$$\text{MAPQ} = -10\log_{10}(P_e)$$

- ただし、 P_e はリードが間違った位置にマップされている確率の推定値。
- MAPQ は、リードがその位置にどの程度ユニークにマップされたかを示す指標であり、その位置でのアライメントスコアが、他のすべての位置におけるスコアよりずっと大きいときに大きくなる。
- Bowtie2 のデフォルトでは同じスコアのアライメントが複数の位置で得られた場合、ランダムに一つの位置を出力し、MAPQ に低い値を設定する。
- MAPQ が低いアライメントの位置は信用できないので、下流の解析の際には捨てた方が良い場合もある。

samtoolsを用いたMAPQによるフィルタリング

- `samtools view -q 閾値 BAMファイル`

MAPQの値が閾値より小さい行を除く

例) MAPQが20以上の行のみを出力

```
$ samtools view -q 20 etec_bowtie2.bam
```

マッピング結果：フラグ (FLAG)

- True/Falseの2状態を1/0で表した変数。複数のフラグをまとめて、2進数の数値で表現される。
- フラグ値は10進数で表示されるが、2進数に変換することで解釈される。

FLAG値

10進数

83

2進数

01010011

解釈

ペアリードである

各リードが適切にアラインされている

逆鎖にマップされている

1番目のリードである

unix コマンドによる 10進数→2進数の変換

```
$ echo 'obase=2;83' | bc
1010011
```

samtools を使ったフラグ値についての確認

```
$ samtools flags 83
0x53    83      PAIRED,PROPER_PAIR,REVERSE,READ1
```

各フラグの説明を表示

```
$ samtools flags
```

Paired end readでのFLAG値



ペアリードがある 両方適切にマッピングされている 自分がマッピングされていない ペア相手がマッピングされていない 逆順にマッピングされた ペア相手は逆順にマッピングされた Read1の配列である Read2の配列である	2進数表記	10進数表記
1 1 1 1 1 1 1 1	11111111	255

通常のpaired end seqで consistentにアラインしていれば この4通りになる	0 1 0 1 0 0 1 1	01010011	83
	0 1 1 0 0 0 1 1	01100011	99
	1 0 0 1 0 0 1 1	10010011	147
	1 0 1 0 0 0 1 1	10100011	163
片方しかアラインしていない場合	0 1 0 0 1 0 0 1	01001001	73
	0 1 0 1 1 0 0 1	01011001	89
	0 1 0 0 0 1 0 1	01000101	69
	0 1 1 0 0 1 0 1	01100101	101
	1 0 0 0 1 0 0 1	10001001	137
	1 0 0 1 1 0 0 1	10011001	153
	1 0 0 0 0 1 0 1	10000101	133
	1 0 1 0 0 1 0 1	10100101	165
どっちもアラインしていない場合	0 1 0 0 1 1 0 1	01001101	77
	1 0 0 0 1 1 0 1	10001101	141

samtoolsを用いたフラグによるフィルタリング

- `samtools view -f フラグ値 BAMファイル`

指定したフラグ値中で1であるフラグが、BAMファイル中のフラグ値でもすべて1になっている行のみを抜き出す。

例) ペアリードでかつ両方が適切にアラインされている行のみを抜き出す

```
$ samtools view -f 3 etec_bowtie2_sorted.bam
```

3は2進数で 11 だから、1番目と2番目のフラグが1である行を抜き出す（それ以外のフラグは無視）

- `samtools view -F フラグ値 BAMファイル`

指定したフラグ値中で1であるフラグが、BAMファイル中のフラグ値ではすべて0になっている行のみを抜き出す。

例) ペアリードの両方が適切にアラインされていない行のみを抜き出す

```
$ samtools view -F 2 etec_bowtie2_sorted.bam
```

2番目のフラグが0である行を抜き出す。

SAM/BAM フォーマット補足

- Bowtie2のデフォルトオプションでマッピングした結果のSAM/BAMファイルは、元のFASTQファイルに含まれている各リードの配列とクオリティデータをすべて含んでいる。以下のコマンドでSAM/BAMファイルからFASTQファイルを作成できる。

```
$ samtools fastq etec_bowtie2.bam -1 r1.fq -2 r2.fq
```

- 個々のリード配列を記録する代わりに、リファレンス配列を参照して、各リードのリファレンス上の位置とアライメント情報のみを記録することによって、さらに圧縮率を高めたバイナリ形式としてCRAM形式がある。

```
$ samtools view -C etec_bowtie2.sam -T eco_o139.fa  
-o etec_bowtie2.cram
```

Bowtie2のオプション3

アライメントのモード

- **--end-to-end** リード配列全長に渡るアライメント
(default)

```
Read:      GACTGGGCGATCTCGACTTCG
           ||||| ||||| ||||| |||
Reference:  GACTG--CGATCTCGACATCG
```

- **--local** リード配列のうち、類似度の高い一部の領域のみ
を抜き出してアラインしたもの

```
Read:      ACGGTTGCGTTAA-TCCGCCACG
           ||||| ||||| |||||
Reference:  TAACTTGCGTTAAATCCGCCTGG
```

マッピング結果：CIGAR文字列

- リードとリファレンス配列とのアライメントの詳細を表す。
- ギャップなしでアラインされている場合 nM (n はリード配列の長さ) となる。
- ギャップが入っている場合、 nD (欠失) または nI (挿入) (n は欠失/挿入長さ) が入る。

5M2D4M1I5M

```
ref  AGACGAGATTA-GCATG
      ⋮ ⋮⋮ ⋮⋮⋮ ⋮⋮⋮ ⋮⋮ ⋮⋮
read ACACG--ATTAGGCTTG
```

- ローカルアライメントのとき、両端の除かれる部分は nS で、またhisat2などのスプライシングを考慮するアライメントにおいて、イントロンとしてスキップされるリファレンス配列上の領域は nN で表される。

5S4M1I5M

```
ref  ACGGCTGATTA-GCATG
      ⋮⋮⋮ ⋮⋮ ⋮⋮
read  taaccATTAGGCTTG
```

Bowtie2のオプション4

検索の精度と速度に関するオプション

- **-N** int seed 検索時にミスマッチを許す数 (0 or 1)
- **-L** int seed の長さ
- **-i** func seed をとる間隔 (リード長を基に決める式を指定)
- **-D** int 最高スコアが更新されないときアライメント計算を打ち切るまでの回数
- **-R** int リードが高反復のseedをもつときにre-seedを行う最大回数

上記のオプションを同時に設定する preset optionがある。

高速（低感度）→ 高感度（低速）の順に4段階のオプションが用意されている。

- end-to-endモードの場合 (default: sensitive)

--very-fast / --fast / --sensitive / --very-sensitive

- localモードの場合 (default: sensitive-local)

--very-fast-local / --fast-local / --sensitive-local / --very-sensitive-local

(参考) HISAT2

スプライシングを考慮した高速マッピングツール

- スプライシングを考慮して、一つのリードをゲノム上で離れた箇所にもたがってマッピングする。
- global とlocalの2つのFMインデックスを2段階で用いることにより、高速かつ正確にスプライスされたアライメントを実現。

