

# 多変量解析


北海道大学大学院農学研究院

(兼) 数理・データサイエンス

教育研究センター


佐藤昌直

# RNA-seq解析における 多変量解析の位置付け



モチベーション:

多次元データを人間が解釈できるように補助する



3遺伝子測定データ → RNA-seq: 数千-数万次元

モチベーション:


多次元データを人間が解釈できるように補助する

→ 高次元データを低次元で表現し  
可視化する

→ 高次元データを統計量で表現し  
特徴を選択する/  
優先順位をつける

高次元（多パラメーター）データの  
認識における問題をどう扱うか？

## クラスタリングによる分類



14 プロファイル  
→ 3 クラスター

# データの確認：目視

Sato\_A\_thaliana-P\_syringae\_avrRpt2\_6h\_expRatio\_small.txt


**をエクセルで開いて見えます。**

# データの確認：Rでの可視化

```
inputMatrix <- read.delim(  
  "gitc/data/MS/Sato_A_thaliana-P_syringae_avrRpt2_6h_expRatio_small.txt",  
  header=TRUE,  
  row.names=1  
)  
str(inputMatrix)      # データの構造を確認する  
image(t(inputMatrix)) # カラーコードで行列データをそのまま可視化  
  
heatmap(as.matrix(inputMatrix)) # 階層クラスタリングとヒートマップ
```

ex601-0

Rは簡単に「何か」を出力してくれる！




統計の基礎知識とRへの正しい命令が必要




高次元（多パラメーター）データの  
認識における問題をどう扱うか？

## クラスタリングによる分類



14 プロファイル  
→ 3 クラスター


# 人間は低次元データだと パターン認識するのは得意



# コンピューターにどうデータを渡せば この問題をどう扱えるか？

人間

遺伝子発現プロ  
ファイルの比較




問題定義の変換


(生物学の問題を数学の問題に置き換える)

計算機


ベクトル等の  
数学で扱える  
特徴量を  
用いた計算



# 7次元の遺伝子発現データセット




# 7遺伝子の発現プロファイル間の類似性は 7次元空間での距離によって決まる




距離の基準を何にするか  
**距離尺度**

# ユークリッド距離




# Uncentered Pearson correlation coefficient = $\cos\theta$





# 相関係数



## Pearson correlation coefficient



# 距離尺度の違い→解析視点の違い:

## 遺伝子発現プロファイルの形と大きさ

- 形: ベクトルの方向
- 大きさ: ベクトルのサイズ



# 解析視点の決め方:



## どの距離尺度を使うか？

- どんなプロファイルを同じプロファイルと定義するか？ 比較したいのは
  - 発現変動の大きさ → ユークリッド距離
  - 発現パターン → コサイン係・相関係数
- 👉 これらを理解するために距離尺度計算の内容を次に確認します


## 距離尺度計算の基本要素:

- **Centering:** 平均値をゼロにする
- **Scaling:** ベクトルの大きさを1にする


# Centering




これらはcentering後は  
全く同じプロファイルになる



# Scaling




これらはscaling後は  
全く同じプロファイルになる






これらはcentering, scaling後は  
**全く同じプロファイル**になる



# アルゴリズムに注目: 相関係数の場合



$$(a_1 - \bar{a})(b_1 - \bar{b}) + (a_2 - \bar{a})(b_2 - \bar{b}) + (a_3 - \bar{a})(b_3 - \bar{b})$$

$$\frac{\sqrt{(a_1 - \bar{a})^2 + (a_2 - \bar{a})^2 + (a_3 - \bar{a})^2} \sqrt{(b_1 - \bar{b})^2 + (b_2 - \bar{b})^2 + (b_3 - \bar{b})^2}}{\sqrt{(a_1 - \bar{a})^2 + (a_2 - \bar{a})^2 + (a_3 - \bar{a})^2} \sqrt{(b_1 - \bar{b})^2 + (b_2 - \bar{b})^2 + (b_3 - \bar{b})^2}}$$

センタリング

スケーリング

# 距離尺度選択における注意点

## 方法依存的に抽出される特徴:

どのような特徴を認識したいのか/  
しているのか意識すること

- 処理間の変動の大きさ: ユークリッド距離
- 処理間のパターンの違い: コサイン係数
- パターンを比較
  - 基準サンプルあり: コサイン係数
  - 基準サンプルなし: 相関係数

# 多変量解析の実際

教師有りか無しか

**(supervised or unsupervised) ?**


- 事前情報、前提はあるか？
- ある場合はk-means法などの利用を検討

どのような距離行列を使うか？


# 多変量解析の実際

階層クラスタリング



# Agglomerative hierarchical clustering



# Agglomerative hierarchical clustering





# Agglomerative hierarchical clustering









# Agglomerative hierarchical clustering




# Agglomerative hierarchical clustering





# Agglomerative hierarchical clustering




# Agglomerative hierarchical clustering




# Agglomerative hierarchical clustering




# クラスター定義手法



# Average linkage




# Complete linkage






# Single linkage



# 階層クラスタリングの利点・欠点



## 利点

- 簡便・直感的な可視化
- デンドログラム長でのクラスター比較

## 欠点

- サンプル・手順依存的
- 1つの距離を指標

# 主成分分析

# 主成分分析とは？

## モチベーション:


多次元データ（多数の遺伝子もしくは多数のサンプル）に含まれる特徴を

- ・ 大きなものから抽出して**新たな軸**を作り
- ・ **情報量の大きな低次元でデータを可視化する**


→ **人間が**新たな解釈を与える

階層クラスタリング:


プロファイル間の類似性は空間での**1つの距離**によって決まる




# PCAは何をするのか？



# PCAは何をするのか？



# PCAは何をするのか？





# PCAの概略(2次元)

1. 各サンプル (1.. $n$ ) の観察値( $x_n, y_n$ )を

$$\begin{aligned} u_n &= a_1 x_n + b_1 y_n \\ v_n &= a_2 x_n + b_2 y_n \end{aligned}$$

とおく

足し算→線形


2.  $a^2 + b^2 = 1$  ,  $u$ と $v$ の相関係数0という制約の下でこれを解いて  $a_n, b_n$  を求める。

# PCAで得られる重要な統計量

- 寄与率
- 因子負荷量
- 主成分得点


# 寄与率

- 各主成分が説明する分散の割合




# 負荷量 loadings

- 得られた主成分と元データのパラメーターの相関
- 各パラメーターがもとのデータの情報をどれだけ有するか



# 主成分得点 scores


- 各パラメーター  
(遺伝子) の値  
を各主成分につ  
いて標準化した  
統計量



標準化: 平均0, SD=1

## biplot:

# 因子負荷量と 主成分得点を 同時に可視化



```
source("gitc/data/MS/multivariate_analysis_source.R")
PCAresults <- pca(inputMatrix)
biplot(PCAresults$scores[,1:2], PCAresults$loadings[,1:2],
       col=c("grey", "black"), cex=c(0.25,0.75))
```

ex601-3で着  
目するPCを決めて可  
視化してください

# 主成分分析(まとめ)

- 主成分分析はデータの分散を説明する新たな軸を計算する方法
  - 寄与率
  - 因子負荷量
  - 主成分得点

# 多次元尺度構成法

Multi-dimensional scaling(MDS),  
Principle coordinate analysis




# 多次元尺度構成法とは？

**モチベーション:**


**多次元での各サンプル間の距離を保持して  
低次元で表現する（多様体学習の1つ）**

⇒ 高次元の距離を低次元に圧縮するため  
軸に意味がない


# PCAが考慮する距離




# MDSが考慮する距離




サンプル間の距離をまず計算する



この定理はサンプル*i,j*に対し、どこを原点  
点（点*k*）としても成り立つ




この定理はサンプル*i,j*に対し、どこを原点（点*k*）としても成り立つ




$$d_{ij}^2 = d_{ik}^2 + d_{jk}^2 - 2d_{ik}d_{jk}\cos\theta$$


# MDSとPCAの違い



Raw data (3 genes)



MDS (2D)



PCA (2 PCs)

# 多次元尺度構成法とは？

**モチベーション:**

**多次元での各サンプル間の距離を保持して  
低次元で表現する**

⇔ 高次元の距離を低次元に圧縮するため  
軸に意味がない



# PCA/MDSのまとめ

データがもつ類似性を低次元で表現し、評価・可視化する

|                               | PCA | MDS                                      |
|-------------------------------|-----|------------------------------------------|
| <b>軸</b> に意味がある               | Yes | No                                       |
| データ全体におけるサンプルの総体的な位置関係を保持するか？ |     |                                          |
| データが線形である場合                   | Yes | Yes/No                                   |
| データが非線形である場合                  | No  | Yes/No<br>データが非線形であるときに局所的な類似関係をうまく表現しうる |

- **重心の置き方に違い:** 入力データをどのように前処理するか

# 多様体学習: 非線形データの多変量解析

モチベーション:

非線形のデータ構造を低次元に圧縮して表現する

- Locally linear embedding
  - Isomap
  - t-SNE
  - UMAP
- } NGS解析にあまり使われないので  
割愛するが、IsomapはMDSの  
延長として勉強するのに有用

注意点: 局所 (サンプル間) の距離・関係を重視し、  
全体の距離は犠牲にしている

# t-SNE, UMAP


モチベーション：

**非線形のデータ構造を低次元に圧縮して表現する**


- 多様な状態のサンプル間の関係性、クラスターを特定する
- single cell omicsデータ解析におけるMDSの立ち位置

# t-SNE, UMAPアルゴリズム概略

1. サンプル間の距離を計算
2. 高次元でのサンプル間距離が低次元でも同様になるよう調整 (embedding, 埋め込み)
  1. **t-SNE**: t-分布を使って距離を調整
  2. **UMAP**: グラフ解析を利用




Step 1: Compute a graphical representation of the dataset



Step 2 (non-parametric): Learn an embedding that preserves the structure of the graph


Sainberg et al. (2009)  
[arXiv:2009.12981](https://arxiv.org/abs/2009.12981)

# 人工非線形データの多変量解析







仮定：3遺伝子（次元）データ

- 時間に変化する細胞集団2つ
- ランダムな状態の細胞集団1つ







- 分布：2次元ではスイスロール
- 残りの1次元: 初めは多様性が低い

# PCA, MDS, t-SNE, UMAP






# t-SNE/UMAPの特徴



# t-SNE/UMAPの特徴



- 近傍のサンプルのクラスター化
- 実空間での距離・サンプル分布は反映しない
  - クラスターサイズは関係ない





# t-SNE/UMAPの違い

- クラスターの分離: UMAP > t-SNE
- 速度: UMAP < t-SNE
- t-SNEは結果が必ず同じ結果になるとは限らない（収束していない可能性がある）




# 多様体学習: 非線形データの多変量解析

- t-SNE
- UMAP
  - : 非線形高次元データのクラスタリングが可能

注意点: 局所（サンプル間）の距離・関係を重視し、  
全体の距離は犠牲にしていることを念頭に  
入れて結果を解釈する必要性あり

# 多変量解析をもう一歩進めて: 入力データは何を使うか？



多変量解析をもう一步進めて:

人間の解釈をアシストするデータ取得を心がける

## 多変量解析の枠組み

多次元（例: 多パラメーター）を  
より少ない指標を使って理解する



N個のサンプルをM個 ( $M < N$ )の  
グループに分類する

→ 人間が新たな解釈を与える

コントロール、  
指標サンプルは  
含められるか？

# 今回の内容で扱わなかった重要項目

- **教師あり多変量解析**
  - k-means法
- **非線形多変量解析・次元圧縮の詳細**

## 連絡：コピーライト

コピーライトは佐藤にあります。  
資料内容の使用については下記連絡先までご  
連絡ください。

- [satox@agr.hokudai.ac.jp](mailto:satox@agr.hokudai.ac.jp)